

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

КУРСОВАЯ РАБОТА
по дисциплине «Дифференциальные уравнения»
Тема: Аппроксимация данных линейной комбинацией
экспоненциальных функций

Студент гр. 2384

Поглазов Н.В.

Студент гр. 2384

Цыганков Р.М.

Преподаватель

Колоницкий С.Б.

Санкт-Петербург

2024

ЗАДАНИЕ НА КУРСОВУЮ РАБОТУ

Студент Поглазов Н.В. Цыганков Р.М.

Группа 2384

Тема работы: Аппроксимация данных линейной комбинацией экспоненциальных функций

Дата выдачи задания: 17.10.2024

Дата сдачи реферата: 14.12.2024

Студент	_____	Поглазов Н.В.
Студент	_____	Цыганков Р.М.
Преподаватель	_____	Колоницкий С.Б.

АННОТАЦИЯ

В курсовой работе рассмотрена задача аппроксимации данных линейной комбинацией экспоненциальных функций. Основной целью исследования было разработать метод для нахождения оптимальных параметров модели с использованием алгоритма Левенберга-Марквардта. Были изучены математические основы метода, критерии сходимости и способы повышения численной устойчивости. Реализация алгоритма выполнена на языке Python с использованием библиотек NumPy и SciPy. Проведены эксперименты на сгенерированных данных, демонстрирующие эффективность предложенного подхода, а также влияние начальных приближений на качество решения. Разработанный метод подтвердил свою практическую применимость для задач анализа данных, что открывает перспективы для его дальнейшего улучшения и расширения.

SUMMARY

The term paper addresses the problem of data approximation using a linear combination of exponential functions. The main objective of the study was to implement a method for finding the optimal model parameters using the Levenberg–Marquardt algorithm. The mathematical foundations of the method, convergence criteria, and approaches to enhancing numerical stability were examined. The algorithm was implemented in Python using the NumPy and SciPy libraries. Experiments on generated data demonstrated the efficiency of the proposed approach, as well as the influence of initial parameter estimates on the solution's quality. The developed method has proven its practical applicability to data analysis tasks, offering potential for further improvement and extension.

СОДЕРЖАНИЕ

1. Выполнение работы	9
1.1. Детали реализации	9
1.1.1. Использование матрицы \mathbf{W}	9
1.1.2. Предобработка данных	9
1.1.3. Обновление параметров	9
1.1.4. Критерии сходимости	10
1.2. Программная реализация алгоритма	11
1.2.1. Структура проекта	11
1.2.2. Класс <code>ExponentialRegression</code>	11
1.2.3. Класс <code>Chi2Loss</code>	14
2. Демонстрация работы программы	16
2.1. Пример с одним экспоненциальным членом	16
2.2. Пример с двумя экспоненциальными членами	16
2.3. Примеры с не экспоненциальными зависимостями	18
2.3.1. Полиномиальная зависимость	18
2.3.2. Синусоидальная зависимость	19
2.3.3. Кривая стандартного нормального распределения	19
Заключение	20
Список использованных источников	22
Приложение А. Исходный код программы	23
A.1. <code>exponential_regression.py</code>	23
A.2. <code>loss/loss_function.py</code>	26
A.3. <code>loss/chi2_loss.py</code>	27
A.4. <code>main.py</code>	28

ВВЕДЕНИЕ

Цель работы.

Разработка и реализация метода аппроксимации ряда данных линейной комбинацией экспоненциальных функций с неизвестными вещественными показателями.

Задание.

Даны $(t_i, y_i)_{i=1}^n$, где $t_i \in \mathbb{R}$, $y_i \in \mathbb{R}$, $i = 1, \dots, n$.

Рассмотрим p — количество экспоненциальных членов, тогда мы подбираем функцию:

$$f : X \rightarrow Y; f(t, \mathbf{p}) = \sum_{i=1}^p \lambda_i \alpha_i^t$$

где $\mathbf{p} = (\lambda_1, \dots, \lambda_p, \alpha_1, \dots, \alpha_p)$ — параметры, которые необходимо подобрать.

Предполагая, что $\forall i \alpha_i > 0$, можно переписать $f(t, \mathbf{p})$ как:

$$f(t, \mathbf{p}) = \sum_{i=1}^p \lambda_i \exp(\ln(\alpha_i)t) = \sum_{i=1}^p \lambda_i \exp(\omega_i t),$$

где $\mathbf{p} = (\lambda_1, \dots, \lambda_p, \omega_1, \dots, \omega_p)$

Функция потерь для оптимизации — это χ^2 , или взвешенный MSE, так как он часто используется в задачах аппроксимации кривых:

$$L(\mathbf{p}) = \chi^2(\mathbf{p}) = \sum_{i=1}^n \left(\frac{y_i - f(t_i, \mathbf{p})}{\sigma_i} \right)^2 = [\mathbf{y} - \mathbf{f}(\mathbf{p})]^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p})],$$

где $\mathbf{W} = \text{diag} \left(\frac{1}{\sigma_1^2}, \dots, \frac{1}{\sigma_n^2} \right)$ - матрица весов: $\sigma_i^2 = \mathbb{D}[y_i]$.

Метод оптимизации — алгоритм Левенберга-Марквардта, встроенный во множество библиотек для оптимизации, например, в SciPy.

Основные теоретические положения.

Подобно другим численным методам минимизации, алгоритм Левенберга-Марквардта является итеративной процедурой. Для начала минимизации необходимо задать начальное приближение для вектора параметров. Начальное значение $\mathbf{p}^T = (1, 1, \dots, 1)$ подходит в большинстве случаев; в задачах с множеством локальных минимумов алгоритм сходится к глобальному минимуму, только если начальное приближение достаточно близко к решению.

На каждом шаге итерации вектор параметров \mathbf{p} заменяется новой оценкой $\mathbf{p} + \Delta$. Чтобы определить Δ , функция $f(t_i, \mathbf{p} + \Delta)$ линеаризуется:

$$f(t_i, \mathbf{p} + \Delta) \approx f(t_i, \mathbf{p}) + \mathbf{J}_i \Delta,$$

где

$$\mathbf{J}_i = \frac{\partial f(t_i, \mathbf{p})}{\partial \mathbf{p}}$$

— это градиент f по параметрам \mathbf{p} .

Таким образом, для текущей задачи $\forall j \leq p$:

$$\mathbf{J}_{ij} = \frac{\partial f(t_i, \mathbf{p})}{\partial \lambda_j} = \exp(\omega_j t_i),$$

$$\mathbf{J}_{ij+p} = \frac{\partial f(t_i, \mathbf{p})}{\partial \omega_j} = \lambda_j t_i \exp(\omega_j t_i).$$

Функция потерь достигает минимума, когда её градиент по \mathbf{p} равен нулю. Для первого приближения $f(t_i, \mathbf{p} + \Delta)$:

$$L(\mathbf{p} + \Delta) \approx \sum_{i=1}^n \left[\frac{y_i - f(t_i, \mathbf{p}) - \mathbf{J}_i \Delta}{\sigma_i} \right]^2$$

или в векторной форме:

$$\begin{aligned}
L(\mathbf{p} + \Delta) &\approx [\mathbf{y} - \mathbf{f}(\mathbf{p}) - \mathbf{J}\Delta]^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p}) - \mathbf{J}\Delta] \\
&= [\mathbf{y} - \mathbf{f}(\mathbf{p})]^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p})] - 2[\mathbf{y} - \mathbf{f}(\mathbf{p})]^T \mathbf{W} \mathbf{J} \Delta + \Delta^T \mathbf{J}^T \mathbf{W} \mathbf{J} \Delta.
\end{aligned}$$

Взяв производную от $L(\mathbf{p} + \Delta)$ по Δ и приравняв её к нулю, получим:

$$(\mathbf{J}^T \mathbf{W} \mathbf{J}) \Delta = \mathbf{J}^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p})].$$

Выражение выше соответствует методу Гаусса–Ньютона. Матрица Якоби \mathbf{J} обычно не квадратная, а прямоугольная размерности $m \times n$, где n — количество параметров. Перемножение $\mathbf{J}^T \mathbf{W} \mathbf{J}$ дает квадратную матрицу размерности $n \times n$. Результат — это система из n линейных уравнений, решаемая для Δ .

Вклад Левенберга заключается в использовании демпфированной версии уравнения:

$$(\mathbf{J}^T \mathbf{W} \mathbf{J} + \lambda \mathbf{E}) \Delta = \mathbf{J}^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p})].$$

где λ — коэффициент демпфирования, изменяемый после каждого вычисления Δ . Если снижение L быстрое, значение λ уменьшается, приближая алгоритм к методу Гаусса–Ньютона:

$$\Delta \approx [\mathbf{J}^T \mathbf{W} \mathbf{J}]^{-1} \mathbf{J}^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p})],$$

иначе λ увеличивается, приближая шаг к направлению градиентного спуска:

$$\Delta \approx \lambda^{-1} \mathbf{J}^T \mathbf{W} [\mathbf{y} - \mathbf{f}(\mathbf{p})].$$

На старте алгоритма λ обычно берется достаточно большим (≈ 1), чтобы делать первые шаги в направлении градиентного спуска. После каждой

итерации λ умножается или делится на определенный фактор, чтобы менять скорость сходимости. Подробности см. в разделе "Выполнение работы" подраздел "Детали реализации".

1. ВЫПОЛНЕНИЕ РАБОТЫ

1.1. Детали реализации

Так как производительность реализации, основанной исключительно на теоретических выкладках, оказалась недостаточной для практического применения, в итоговом решении были внесены несколько улучшений.

1.1.1. Использование матрицы \mathbf{W}

Поскольку мы имеем дело исключительно с синтетическими данными, и измерение y_i проводятся единожды с заранее заданной (одинаковой) дисперсией, использование матрицы весов является избыточным. По этой причине в итоговой реализации $\mathbf{W} = \mathbf{E}$.

1.1.2. Предобработка данных

Для повышения численной устойчивости было принято решение стандартизировать данные перед обучением модели. Для этого используется формула:

$$x_i = \frac{x_i - \mu}{\sigma},$$

то есть, после предобработки все значения признаков будут иметь нулевое среднее и единичное стандартное отклонение. Также этот метод не меняет форму распределения данных, что важно для сохранения интерпретируемости результатов.

1.1.3. Обновление параметров

Ранее, найденная Δ применялась, если функция потерь уменьшалась, иначе она отклонялась, а коэффициент демпфирования увеличивался. Теперь шаг принимается, если метрика ρ (была предложена Нильсеном в его статье

1999 года [3]) больше порогового значения $\varepsilon_4 > 0$. Эта метрика измеряет фактическое уменьшение χ^2 по сравнению с улучшением, достигаемым шагом метода Левенберга-Марквардта:

$$\begin{aligned}\rho &= \frac{\chi^2(\mathbf{p}) - \chi^2(\mathbf{p} + \Delta)}{|(\mathbf{y} - \hat{\mathbf{y}})^T \mathbf{W}(\mathbf{y} - \hat{\mathbf{y}}) - (\mathbf{y} - \hat{\mathbf{y}} - \mathbf{J}\Delta)^T \mathbf{W}(\mathbf{y} - \hat{\mathbf{y}} - \mathbf{J}\Delta)|} \\ &= \frac{\chi^2(\mathbf{p}) - \chi^2(\mathbf{p} + \Delta)}{|\Delta^T (\lambda \Delta + \mathbf{J}^T \mathbf{W}(\mathbf{y} - \hat{\mathbf{y}}))|}\end{aligned}$$

где $\hat{\mathbf{y}} = \mathbf{f}(\mathbf{p})$.

Коэффициент демпфирования и параметры модели обновляются согласно следующим правилам:

Если $\rho > \varepsilon_4$:

$$\lambda = \max \left[\frac{\lambda}{L_{\downarrow}}, 10^{-7} \right], \mathbf{p} \leftarrow \mathbf{p} + \Delta$$

иначе:

$$\lambda = \min [\lambda L_{\uparrow}, 10^7], \mathbf{p} \leftarrow \mathbf{p}$$

где $L_{\downarrow} \approx 9$ и $L_{\uparrow} \approx 11$ — фиксированные константы. Эти значения хорошо показали себя на практике и были выбраны на основе статьи [2].

1.1.4. Критерии сходимости

Алгоритм останавливается, когда выполняется *одно* из следующих условий:

- Сходимость по градиенту: $\max |\mathbf{J}^T \mathbf{W}(\mathbf{y} - \hat{\mathbf{y}})| < \varepsilon_1$
- Сходимость по коэффициентам: $\max |\Delta/\mathbf{p}| < \varepsilon_2$
- Сходимость по (редуцированному) χ^2 : $\chi_{\nu}^2 = \chi^2/(m - n) < \varepsilon_3$

1.2. Программная реализация алгоритма

Для реализации алгоритма был выбран язык программирования Python, так как он предоставляет широкие возможности для научных вычислений и имеет большое количество библиотек для работы с данными. В качестве основной библиотеки для работы с данными была выбрана библиотека NumPy, а для работы с графиками — Matplotlib.

1.2.1. Структура проекта

Проект разделен на следующие модули:

- `exponential_regression.py` — модуль с реализацией алгоритма в классе `ExponentialRegression`
- `loss/loss_function.py` — модуль с реализацией базового класса для функций потерь `LossFunction`
- `loss/chi2_loss.py` — модуль с реализацией функции потерь χ^2 в классе `Chi2Loss`
- `main.py` — точка входа в программу, содержит пример использования алгоритма

1.2.2. Класс `ExponentialRegression`

Класс `ExponentialRegression` реализует регрессионную модель на основе экспоненциальных функций. Он наследует `BaseEstimator` и `RegressorMixin` из библиотеки `scikit-learn`, что делает его совместимым с её API. Основное назначение класса `ExponentialRegression` — обучение и предсказание на основе экспоненциальной зависимости.

При создании экземпляра класса задаются следующие параметры:

- `n_terms` (int, по умолчанию 1): число экспоненциальных членов в модели.

- `max_iter` (int, по умолчанию 1000): максимальное число итераций для процедуры оптимизации.
- `gradient_tol` (float, по умолчанию 10^{-3}): порог для остановки оптимизации по величине градиента.
- `coefficients_tol` (float, по умолчанию 10^{-3}): порог для изменения коэффициентов модели.
- `chi2_reduced_tol` (float, по умолчанию 0.1): порог для среднего значения χ^2 .
- `step_acceptance` (float, по умолчанию 0.1): минимальное значение отношения улучшения шага для принятия шага.
- `reg_init` (float, по умолчанию 0.1): начальное значение λ .
- `loss_function` (LossFunction, по умолчанию Chi2Loss): функция потерь, используемая для вычисления градиента, гессиана и значения ошибки.

В дополнение к параметрам инициализации, класс определяет несколько предустановленных констант, $L \uparrow$ – `REG_INCREASE_FACTOR`, $L \downarrow$ – `REG_DECREASE_FACTOR`, а также нижняя и верхняя граница λ – `REG_MIN` и `REG_MAX`.

```
fit(data, target, initial_lambda=None,
    initial_omega=None):
```

Метод обучает модель на основе входных данных:

- `data` (np.ndarray): одномерный массив временных значений.
- `target` (np.ndarray): одномерный массив значений целевой переменной.

- `initial_lambda(Optional[np.ndarray])`: начальные значения коэффициентов , если заданы.
- `initial_omega(Optional[np.ndarray])`: начальные значения параметров , если заданы.

Для решения системы $[\mathbf{J}^T \mathbf{W} \mathbf{J}] \Delta = \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}})$ используется функция `scipy.linalg.solve` из библиотеки SciPy.

`predict(data):`

Метод делает предсказания для входных данных `data`:

- `data(np.ndarray)`: одномерный массив временных значений.

Приватные (вспомогательные) методы:

- `_init_parameters(n_terms)`: инициализация параметров \mathbf{p} .
- `_jacobian(t)`: вычисление якобиана.
- `_regularize_hessian(hessian)`: демпфирование гессиана.
- `_accept_step(t, y_true, y_pred, delta, gradient)`: проверка, является ли шаг улучшением, и обновление параметров в случае успеха.
- `_increase_regularization()`: увеличение λ .
- `_decrease_regularization()`: уменьшение λ .
- `_check_convergence(gradient, lambda_delta, omega_delta, loss, measurements_amount)`: проверка условий сходимости.
- `_model(t, lambda_=None, omega_=None)`: вычисление $f(\mathbf{t}, \mathbf{p})$.

1.2.3. Класс Chi2Loss

Класс `Chi2Loss` реализует функцию потерь χ^2 . Он наследует `LossFunction` и реализует методы для вычисления градиента, гессиана и значения функции потерь.

При создании экземпляра класса задаются следующие параметры:

- `measurements_amount (int)`: количество измерений;
- `measurement_variance (np.ndarray | float | None, по умолчанию None)`: дисперсия каждого измерения или общая дисперсия;

с помощью которых вычисляется матрица весов \mathbf{W} .

`loss(y_true, y_pred):`

Метод вычисляет значение функции потерь:

$$\chi^2 = [\mathbf{y} - \hat{\mathbf{y}}]^T \mathbf{W} [\mathbf{y} - \hat{\mathbf{y}}],$$

`gradient(t, y_true, y_pred, jacobian):`

Метод вычисляет (анти-) градиент функции потерь деленный на 2 (для удобства в использовании):

$$-\frac{1}{2} \frac{\partial \chi^2}{\partial \mathbf{p}} = \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}})$$

`hessian(jacobian):`

Метод (приближенно) вычисляет гессиан функции потерь:

$$\frac{\partial^2 \chi^2}{\partial \mathbf{p}^2} \approx \mathbf{J}^T \mathbf{W} \mathbf{J}$$

где $\hat{\mathbf{y}}$ - `y_pred`, \mathbf{y} - `y_true`, \mathbf{J} - `jacobian`, \mathbf{W} - диагональная матрица весов.

Реализованный код см. в приложении А, по ссылке: <https://github.com/Nekson228/ExponentialRegression/tree/main>, или по QR-коду:



2. ДЕМОНСТРАЦИЯ РАБОТЫ ПРОГРАММЫ

2.1. Пример с одним экспоненциальным членом

Для примера были сгенерированы данные, соответствующие зависимости $f(t) = 2 \exp(-0.25t) + \varepsilon$, $\varepsilon \in \mathcal{N}(0, 1)$ — случайный шум.

Было проведено 100 замеров в диапазоне $t \in [-10, 10]$. После обучения модели были получены следующие результаты:




Рисунок 1 – Пример с одним экспоненциальным членом

Как видно из графика, модель хорошо отфильтровала шум и восстановила исходную зависимость.

2.2. Пример с двумя экспоненциальными членами

Для примера были сгенерированы данные, соответствующие зависимости $f(t) = 2 \exp(-0.25t) - 5 \exp(-2t) + \varepsilon$, $\varepsilon \in \mathcal{N}(0, 0.1^2)$ — случайный шум.

Было проведено 100 замеров в диапазоне $t \in [0, 10]$. После обучения модели были получены следующие результаты:




Рисунок 2 – Пример с двумя экспоненциальными членами

Как видно из графика, модель не смогла восстановить исходную зависимость. Это связано с тем, что функция потерь $\chi^2(\mathbf{p})$ может иметь множество локальных минимумов. В таких случаях метод Левенберга-Марквардта может сходиться к неудовлетворительному решению. Если это происходит, пользователь может попытаться задать лучшее начальное приближение для параметров, например, с помощью случайного поиска, или поиска по сетке, либо путем анализа данных.

Попробуем улучшить результат, вручную задав начальные приближения для параметров:

$$\lambda = \begin{bmatrix} 1 & -1 \end{bmatrix}$$

$$\omega = \begin{bmatrix} -1 & -1 \end{bmatrix}$$

После обучения модели с новыми начальными приближениями были получены следующие результаты:

Как видно из графика, модель восстановила исходную зависимость. Это показывает, что правильный выбор начальных приближений для параметров может существенно повлиять на результат.




Рисунок 3 – Пример с двумя экспоненциальными членами (улучшенный результат)

Написанный алгоритм позволяет удобно и быстро решать задачи аппроксимации данных линейной комбинацией экспоненциальных функций. Он легко расширяется на случай большего числа экспоненциальных членов, а также на случай других функций потерь.

2.3. Примеры с не экспоненциальными зависимостями

Попробуем провести подгон параметров модели к зависимостям, не являющимся линейной комбинацией экспоненциальных членов.

2.3.1. Полиномиальная зависимость

Для примера были сгенерированы данные, соответствующие зависимости $f(t) = 2 + 3t + 4t^2 + 5t^3$. Было проведено 100 замеров в диапазоне $t \in [-2, 1]$.

После 2х попыток перебора начальных приближений для параметров, модель из 2-х экспоненциальных членов смогла неплохо аппроксимировать зависимость.




Рисунок 4 – Пример с полиномиальной зависимостью

2.3.2. Синусоидальная зависимость

Для примера были сгенерированы данные, соответствующие зависимости $f(t) = \sin(t)$. Было проведено 100 замеров в диапазоне $t \in [-2, 1]$.

Для подбора начальных приближений использовался метод случайного поиска параметров в диапазоне $[-5, 5]$. После 1000 итераций поиска была выбрана лучшая (по итоговому значению χ^2) модель из 4-х экспоненциальных членов.

2.3.3. Кривая стандартного нормального распределения

Для примера были сгенерированы данные, соответствующие зависимости $f(t) = \exp(-t^2)$. Было проведено 100 замеров в диапазоне $t \in [-3, 3]$.

Для подбора начальных приближений использовался метод случайного поиска параметров в диапазоне $[-10, 10]$. После 1000 итераций поиска была выбрана лучшая модель из 10-ти экспоненциальных членов.




Рисунок 5 – Пример с синусоидальной зависимостью




Рисунок 6 – Пример с кривой стандартного нормального распределения

ЗАКЛЮЧЕНИЕ

В процессе выполнения курсовой работы была достигнута цель, заключающаяся в разработке метода аппроксимации данных линейной комбинацией экспоненциальных функций с использованием алгоритма Левенберга-Марквардта. Были детально изучены основные математические принципы

алгоритма, включая оптимизационные подходы, такие как градиентный спуск и метод Гаусса–Ньютона, а также особенности их сочетания в демпфированном виде.

Важным этапом стало внедрение методов повышения численной устойчивости, включая стандартизацию данных и адаптивное управление коэффициентом демпфирования. Реализованная модель продемонстрировала свою эффективность на тестовых данных, успешно аппроксимируя зависимости с одним и двумя экспоненциальными членами. Тем не менее, результаты также выявили чувствительность метода к выбору начальных приближений параметров, что требует дополнительного внимания при его применении.

Практическая реализация была выполнена на языке программирования Python с использованием современных библиотек для численных вычислений и визуализации. Предложенный подход может быть расширен для решения более сложных задач, например, с увеличением числа экспоненциальных членов или использованием других функций потерь. Разработанный алгоритм и полученные результаты подчеркивают его потенциал для дальнейших исследований и применения в задачах анализа данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Wikipedia contributors. *Levenberg–Marquardt algorithm*. Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/wiki/Levenberg%E2%80%93Marquardt_algorithm.
- [2] H. P. Gavin. *The Levenberg-Marquardt algorithm for nonlinear least squares curve-fitting problems*. 2020. <https://people.duke.edu/~hpgavin/ce281/lm.pdf>.
- [3] H. B. Nielsen. *Damping Parameter in Marquardt's Method*. 1999. https://www2.imm.dtu.dk/documents/ftp/tr99/tr05_99.pdf.

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД ПРОГРАММЫ

A.1. exponential_regression.py

```
from typing import Self, Optional

import numpy as np

from sklearn.base import BaseEstimator, RegressorMixin
from sklearn.utils.validation import check_X_y, check_array

from .loss import LossFunction

class ExponentialRegression(BaseEstimator, RegressorMixin):
    GRADIENT_TOL: float = 1e-3
    COEFFICIENTS_TOL: float = 1e-3
    CHI_SQR_REDUCED_TOL: float = 1e-1
    STEP_ACCEPTANCE: float = 1e-1

    REG_INIT: float = 1e-1
    REG_INCREASE_FACTOR: float = 11.
    REG_DECREASE_FACTOR: float = 9.
    REG_MIN: float = 1e-7
    REG_MAX: float = 1e7

    def __init__(self,
                 n_terms: int = 1,
                 *,
                 max_iter: int = 1000,
                 gradient_tol: float = GRADIENT_TOL,
                 coefficients_tol: float = COEFFICIENTS_TOL,
                 chi2_reduced_tol: float = CHI_SQR_REDUCED_TOL,
                 step_acceptance: float = STEP_ACCEPTANCE,
                 reg_init: float = REG_INIT,
                 loss_function: LossFunction = None,
                 initial_lambda: Optional[np.ndarray] = None,
                 initial_omega: Optional[np.ndarray] = None,
                 ) -> None:
        self.n_terms = n_terms
        self.max_iter = max_iter
        self.initial_lambda = initial_lambda
        self.initial_omega = initial_omega

        self.gradient_tol = gradient_tol
        self.coefficients_tol = coefficients_tol
        self.chi2_reduced_tol = chi2_reduced_tol
        self.step_acceptance = step_acceptance

        self.reg_init = reg_init
        self.regularization_ = self.reg_init

        self.loss_function = loss_function

        self.lambda_ = initial_lambda if initial_lambda is not None else np.
            ones(n_terms)
        self.omega_ = initial_omega if initial_omega is not None else np.ones(
            n_terms)
```

```

self.loss_: Optional[float] = None

def fit(self, data: np.ndarray, target: np.ndarray) -> Self:
    data, target = check_X_y(data, target, ensure_2d=False)
    t = data.ravel()

    new_y_pred = self._model(t)
    is_step_accepted = True
    hessian = gradient = delta = None

    for _ in range(self.max_iter):
        y_pred = new_y_pred
        if is_step_accepted:
            jacobian = self._jacobian(t)
            gradient = self.loss_function.gradient(target, y_pred,
                                                    jacobian)
            self.loss_ = self.loss_function.loss(target, y_pred)
            hessian = self.loss_function.hessian(jacobian)

        hessian = self._regularize_hessian(hessian)

        delta = np.linalg.solve(hessian, gradient)

        if self._check_convergence(gradient, delta, data.size):
            break

        is_step_accepted, new_y_pred = self._accept_step(t, target, y_pred,
                                                         delta, gradient)
        if is_step_accepted:
            self._decrease_regularization()
        else:
            self._increase_regularization()
    else:
        print(f"Failed to converge after {self.max_iter} iterations")

    return self

def _jacobian(self, t: np.ndarray) -> np.ndarray:
    exp_terms = np.exp(np.outer(t, self.omega_))
    jacobian_lambda = exp_terms
    jacobian_omega = exp_terms * self.lambda_ * t[:, np.newaxis]
    jacobian = np.hstack((jacobian_lambda, jacobian_omega))
    return jacobian

def _regularize_hessian(self, hessian: np.ndarray) -> np.ndarray:
    return hessian + np.eye(hessian.shape[0]) * self.regularization_

def _accept_step(self,
                 t: np.ndarray,
                 y_true: np.ndarray,
                 y_pred: np.ndarray,
                 delta: np.ndarray,
                 gradient: np.ndarray,
                 ) -> tuple[bool, np.ndarray]:
    new_lambda = self.lambda_ + delta[:self.n_terms]
    new_omega = self.omega_ + delta[self.n_terms:]
    new_y_pred = self._model(t, new_lambda, new_omega)

    chi_sqr = self.loss_function.loss(y_true, y_pred)
    new_chi_sqr = self.loss_function.loss(y_true, new_y_pred)

    rho = (chi_sqr - new_chi_sqr) / np.abs(
        delta.T @ (self.regularization_ * delta + gradient)
    )

```



```

)

if rho > self.step_acceptance:
    self.lambda_ = new_lambda
    self.omega_ = new_omega
    return True, new_y_pred
return False, y_pred

def _increase_regularization(self) -> None:
    self.regularization_ *= self.REG_INCREASE_FACTOR
    self.regularization_ = min(self.regularization_, self.REG_MAX)

def _decrease_regularization(self) -> None:
    self.regularization_ /= self.REG_DECREASE_FACTOR
    self.regularization_ = max(self.regularization_, self.REG_MIN)

def _check_convergence(self,
                        gradient: np.ndarray,
                        delta: np.ndarray,
                        measurements_amount: int) -> bool:
    return (
        np.max(np.abs(gradient)) < self.gradient_tol
        or np.max(np.abs(delta[:self.n_terms] / self.lambda_)) < self.
            coefficients_tol
        or np.max(np.abs(delta[self.n_terms:] / self.omega_)) < self.
            coefficients_tol
        or self.loss_ / (measurements_amount - gradient.shape[0]) <
            self.chi2_reduced_tol
    )

def predict(self, data: np.ndarray) -> np.ndarray:
    data = check_array(data, ensure_2d=False)
    t = data.ravel()
    return self._model(t)

def _model(self,
            t: np.ndarray,
            lambda_: Optional[np.ndarray] = None,
            omega_: Optional[np.ndarray] = None,
            ) -> np.ndarray:
    lambda_ = self.lambda_ if lambda_ is None else lambda_
    omega_ = self.omega_ if omega_ is None else omega_

    exp_terms = np.exp(np.outer(t, omega_))
    return exp_terms @ lambda_

```

A.2. loss/loss_function.py

```
from abc import ABC, abstractmethod
import numpy as np
from typing import Optional

class LossFunction(ABC):
    def __repr__(self) -> str:
        return self.__class__.__name__

    @abstractmethod
    def loss(self, y_true: np.ndarray, y_pred: np.ndarray) -> float:
        """
        Compute the loss function given the residuals
        param y_true: true values
        param y_pred: predicted values
        """
        pass

    @abstractmethod
    def gradient(self, y_true: np.ndarray, y_pred: np.ndarray, jacobian: np.
        ndarray) -> np.ndarray:
        """
        Compute the gradient of the loss function
        param y_true: true values
        param y_pred: predicted values
        param jacobian: jacobian of the model
        """
        pass

    @abstractmethod
    def hessian(self, jacobian: np.ndarray) -> np.ndarray:
        """
        Compute the hessian of the loss function
        param jacobian: jacobian of the model
        """
        pass
```

A.3. loss/chi2_loss.py

```
import numpy as np
from typing import Optional

from .loss_function import LossFunction

class Chi2Loss(LossFunction):
    # Chi-squared (or weighted MSE) loss function
    def __init__(self, measurements_amount: int, measurement_variance: float |
        np.ndarray | None = None) -> None:
        if isinstance(measurement_variance, float):
            self._weights = np.eye(measurements_amount) / measurement_variance
        elif isinstance(measurement_variance, np.ndarray):
            self._weights = np.diag(1 / measurement_variance)
        else:
            self._weights = np.eye(measurements_amount)

    def loss(self, y_true: np.ndarray, y_pred: np.ndarray) -> float:
        residuals = y_true - y_pred
        return np.float_(residuals.T @ self._weights @ residuals)

    def gradient(self, y_true: np.ndarray, y_pred: np.ndarray, jacobian: np.
        ndarray) -> np.ndarray:
        residuals = y_true - y_pred
        return jacobian.T @ self._weights @ residuals

    def hessian(self, jacobian: np.ndarray) -> np.ndarray:
        return jacobian.T @ self._weights @ jacobian
```

A.4. main.py

```
import numpy as np

import matplotlib.pyplot as plt

from sklearn.preprocessing import StandardScaler

from src.exponential_regression import ExponentialRegression
from src.loss.chi2_loss import Chi2Loss


def main():
    measurements = 100
    measurement_errors = 1 / 20
    x = np.linspace(0, 10, measurements).reshape(-1, 1)
    y = (2 * np.exp(-0.25 * x) + (-5) * np.exp(-2 * x)).ravel()
    y += np.random.normal(0, measurement_errors, measurements)

    scaler = StandardScaler()
    x = scaler.fit_transform(x)

    loss = Chi2Loss(measurements, measurement_errors)

    er = ExponentialRegression(n_terms=2, loss_function=loss,
                               initial_lambda=np.array([1., -1.]),
                               initial_omega=np.array([-1., -1.]))

    er.fit(x, y)
    coefficients = np.hstack((er.lambda_, er.omega_))
    print(coefficients)

    plt.scatter(x, y)
    plt.plot(x, er.predict(x), color='red')
    plt.show()


if __name__ == '__main__':
    main()
```